



**Tecnológico
de Monterrey**

INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE MONTERREY

Maestría en Inteligencia Artificial:

Tarea 8: Usando funciones de Machine Learning en la nube

Alumno: Oscar Enrique García García - A01016093

Profesor Titular: Gilberto Echeverría Furió

Profesor asistente: Yetnalezi Quintas Ruiz

Cómputo en la nube

22 de marzo de 2026

Índice

1. Introducción	1
2. Sección de Azure ML para trabajar con libretas	2
2.1. Creación del servicio	2
2.2. Creación y configuración del notebook	7
2.3. Carga de datos	12
2.4. Ejecución de código en cuaderno de trabajo y análisis de datos	21
2.4.1. Hallazgos del análisis de los datos	27
3. Investigación de proceso de Azure AutoML	33
3.1. ¿Qué es AutoML?	33
3.2. Configuración del servicio y carga de datos	34
3.3. Resultados	44
3.4. Implementación del modelo para predicciones	52
4. Reflexión	55
5. Referencias	57

1. Introducción

El Machine Learning (ML) o aprendizaje automático es una rama de la inteligencia artificial que permite a los sistemas aprender de los datos para realizar tareas sin ser programados explícitamente para cada una de ellas.

En la actualidad, el uso de funciones de ML en la nube, particularmente a través de plataformas como Azure Machine Learning, ha democratizado el acceso a herramientas avanzadas para científicos de datos y empresas.

Ventajas y Desventajas del Machine Learning Tradicional

-Ventajas: Permite automatizar procesos complejos, realizar predicciones precisas y manejar grandes volúmenes de datos que serían inmanejables para un humano.

-Desventajas: El ciclo de vida tradicional de ML es costoso en tiempo y requiere que expertos prueben manualmente algoritmos, ajusten hiperparámetros y realicen ingeniería de características repetitiva.

Plataformas como Azure ofrecen entornos robustos que facilitan desde la creación de libretas de trabajo (notebooks .ipynb) hasta la implementación con herramientas como Auto ML, que facilitan todas las tareas repetitivas y tediosas que tienen que hacer los científicos de datos, previo a un análisis y optimización.

Esta práctica pretende demostrar cómo implementar scripts de python dentro de Azure, así como demostrar las ventajas y facilidad con la que se pueden automatizar todas estas tareas repetitivas dentro de un entorno de nube.

2. Sección de Azure ML para trabajar con libretas

A continuación se mostrarán los pasos que se siguieron para crear un notebook (.ipynb) dentro de la nube de Azure, con el servicio de Azure ML.

2.1. Creación del servicio

El primer paso para crear nuestro servicio de Azure ML, es entrar al portal de Azure

Servicios de Azure

[Crear un recurso](#)
[Grupos de recursos](#)
[Azure SQL Database](#)
[Todos los recursos](#)
[Suscripciones](#)
[Máquinas virtuales](#)
[Virtual Machines...](#)
[Cuentas de almacenamie...](#)
[Grupos](#)
[Más servicios](#)

Recursos

[Reciente](#)
[Favorito](#)

Nombre	Tipo	Última consulta
TextSpeechMNAOG	Cuenta de varios servicios de Azure AI	hace 4 días
GR-TextSpeech-API-Python	Grupo de recursos	hace 4 días
FaceRecognitionMNAOG	Cuenta de varios servicios de Azure AI	hace 4 días
GR-FaceRecog-API-Python	Grupo de recursos	hace 4 días
oeggtstadb	Servidor flexible de Azure Database for MySQL	hace 2 semanas
grupo-db	Grupo de recursos	hace 2 semanas
Azure for Students	Suscripción	hace 2 semanas
personalazurewebserver-ip	Dirección IP pública	hace 2 semanas
vnet-canadacentral	Red virtual	hace 2 semanas
personalazurewebserver	Máquina virtual	hace 2 semanas
personalazurewebserver690_z1	Interfaz de red	hace 2 semanas
personalazurewebserver-nsg	Grupo de seguridad de red	hace 2 semanas

[Ver todo](#)

Figura 1: Azure Portal, pantalla principal.

Una vez dentro del portal, podemos dar clic en «Crear un recurso» y, en la barra de búsqueda, buscaremos «machine learning».




Figura 2: Servicios de Machine Learning en Azure.

Una vez desplegados los servicios, ubicaremos el servicio de «Azure Marchine Learning» y daremos clic en el botón «Crear» que se encuentra debajo y después en «Azure Machine Learning».




Figura 3: Azure Machine Learning.

Posteriormente se abrirá una pantalla de configuración del servicio donde configuraremos lo siguiente:

Inicio > Crear un recurso > Marketplace

Azure Machine Learning

Creación de un área de trabajo de Machine Learning

Aspectos básicos

Inbound Access

Outbound Access

Cifrado

Identidad

Etiquetas

Revisión y creación

Detalles del recurso

Todas las áreas de trabajo deben asignarse a una suscripción de Azure, que es donde se realiza la facturación. Use grupos de recursos como carpetas para organizar y administrar recursos, incluido el área de trabajo que va a crear.

[Más información sobre los grupos de recursos de Azure](#)

Suscripción *

Azure for Students

Grupo de recursos *

(Nuevo) gr-machinelearning

[Crear nuevo](#)

Detalles del área de trabajo

Configure las opciones básicas del área de trabajo, como la conexión de almacenamiento, la autenticación, el contenedor y mucho más. [Más información](#)

Nombre *

azureml-mna

Región *

Canada Central

Cuenta de almacenamiento *

(nuevo) azuremlmna7567012943

[Crear nuevo](#)

Almacén de claves *

(nuevo) azuremlmna8437114189

[Crear nuevo](#)

Application Insights *

(nuevo) azuremlmna3060951041

[Crear nuevo](#)

Registro de contenedor

Ninguno

[Crear nuevo](#)

Revisión y creación

< Anterior

Siguiente: Inbound Access

Figura 4: Configuración inicial del servicio de Azure ML.

- **Suscripción:** Seleccionaremos nuestra suscripción (Azure for Students).
- **Grupo de recursos:** Daremos clic en crear nuevo y definiremos uno nuevo con el nombre gr-machinelearning.

- **Nombre:** Definiremos un nombre que identifique a nuestro servicio. En nuestro caso, Azure ML-mna.
- **Región:** Definiremos una región, de acuerdo a nuestras regiones disponibles.

Una vez seleccionado el nombre, veremos que también se llenan de forma automática los campos de cuenta de almacenamiento, almacén de claves y application insights. Estos valores los dejaremos tal cual se crearon.

Para el menú de registro de contenedor, seleccionaremos el valor de «Ninguno».

Una vez configurado lo anterior, daremos clic en «Siguiente: Inbound Access», que nos llevará nuevamente a otra pantalla de configuración. En esta pantalla únicamente verificaremos que esté seleccionado «All networks» en la sección de «Public network access».

Inicio > Crear un recurso > Marketplace

Azure Machine Learning

Creación de un área de trabajo de Machine Learning

Aspectos básicos **Inbound Access** Outbound Access Cifrado Identidad Etiquetas Revisión y creación

El acceso a la red pública permite el acceso a este recurso a través de Internet mediante una dirección IP pública. Una aplicación o recurso al que se concede acceso con las siguientes reglas de red sigue necesitando la autorización adecuada para acceder a este recurso. [Más información](#)

Public network access *

☐ Disabled

☒ All networks

ⓘ Todas las redes, incluso Internet, pueden acceder a este recurso.

Acceso entrante al área de trabajo

Nombre	Suscripción	Grupo de recursos	Región	Subred	Zona DNS privada
Hacer clic en Agregar para crear un punto de conexión privado					
+ Agregar					

Revisión y creación < Anterior Siguiente: Outbound Access

Figura 5: Configuración de inbound access para Azure ML.

Finalmente, podemos dar clic en el botón «Revisión y creación», que nos llevará a una pantalla de resumen de nuestra configuración y, después de haber sido validado, nos dejará dar clic en el botón «Crear» para iniciar el proceso de creación de nuestro servicio.

Inicio > Crear un recurso > Marketplace

Azure Machine Learning

Creación de un área de trabajo de Machine Learning

Aspectos básicos Inbound Access Outbound Access Cifrado Identidad Etiquetas Revisión y creación

Suscripción	Azure for Students
Grupo de recursos	(Nuevo) gr-machinelearning
Región	Canada Central
Nombre	azureml-mna
Cuenta de almacenamiento	(nuevo) azuremlmna7567012943
Almacén de claves	(nuevo) azuremlmna8437114189
Application Insights	(nuevo) azuremlmna3060951041
Registro de contenedor	Ninguno
Método de conectividad	Habilitar el acceso público desde todas las redes
Aislamiento de red	Público
Tipo de cifrado	Claves administradas por Microsoft
Tipo de identidad	Asignada por el sistema
Habilitar marca HBI	Deshabilitado
Tipo de acceso a la cuenta de almacenamiento	Basado en credenciales
Acceso de clave compartida	Habilitado

Crear

< Anterior

Siguiente >

[Descargar una plantilla para la automatización](#)

Figura 6: Creación del servicio Azure ML

2.2. Creación y configuración del notebook

Una vez que se completó la creación de nuestro servicio, nos aparecerá un botón de «Ir al recurso», al cual daremos clic para entrar a la configuración general del servicio.




Figura 7: Servicio creado exitosamente.

Una vez que estemos en la pantalla de «Información general» de nuestro servicio recién creado, daremos clic en el botón «Launch Studio».




Figura 8: Información general del servicio - Launch Studio.

Al dar clic en el botón, se nos mostrará una nueva pantalla de inicio de Azure ML. Aquí, se muestran las diferentes opciones para trabajar con proyectos de Data Science. En esta ocasión, mostraremos cómo crear y configurar un *notebook* de Python desde este entorno de trabajo.

Para ello, buscaremos la opción de «Crear cuaderno» dentro de la sección «Accesos directos» y daremos clic en el botón «Crear nuevo bloc de notas» que se encuentra debajo y procederemos a darle un nombre a nuestro cuaderno.




Figura 9: Creando un nuevo cuaderno de trabajo en Azure ML.




Figura 10: Nombrando nuestro cuaderno de trabajo en Azure ML.

Ya que hemos nombrado nuestro cuaderno de trabajo, se abrirá nuestro cuaderno de trabajo donde podremos ingresar nuestro código Python dentro de las celdas, pero

antes de poder ejecutar cualquier código, debemos configurar un nuevo «entorno de procesamiento de Azure ML».

Para ello, buscaremos y daremos clic en el botón «+» que se encuentra en la sección «Proceso» que se sitúa en la parte superior de la pantalla.




Figura 11: Crear nuevo proceso de Azure ML.

Este botón nos llevará a diferentes pantallas de configuración donde definiremos lo siguiente:

The screenshot shows the 'Creación de instancias de proceso' (Process instance creation) configuration screen. It has a sidebar with steps: 1. Valores obligatorios, 2. Programación, 3. Seguridad, 4. Aplicaciones, 5. Etiquetas, and 6. Revisar. The main area is titled 'Configurar los valores obligatorios' and contains the following fields:

- Nombre del proceso:** AzureML-compute-MNA-OEGG
- Tipo de máquina virtual:** CPU (selected), GPU
- Tamaño de la máquina virtual:** Selecionar de entre las opciones recomendadas (selected), Selecionar de entre todas las opciones

A table lists the recommended virtual machine sizes:

Nombre	Categoría	Tipos de carga de trabajo	Cuota disponi...	Costo
Standard_DS11_v2 2 núcleos, 14 GB de RAM, 28 GB de almacenamiento	Optimizada para ...	Desarrollo en cuadernos (u otros IDE) y pruebas atenuadas	6 núcleos	3.2 MXN/h
Standard_DS3_v2 4 núcleos, 14 GB de RAM, 28 GB de almacenamiento	De uso general	Entrenamiento de modelos clásicos de ML en conjuntos de datos pequeños	6 núcleos	5 MXN/h
Standard_E4ds_v4 4 núcleos, 32 GB de RAM, 150 GB de almacenamiento	Optimizada para ...	Manipulación y entrenamiento de datos en conjuntos de datos de tamaño mediano (1-10 GB)	4 núcleos	5.7 MXN/h

At the bottom, there are buttons: 'Revisar y crear', 'Atrás', 'Siguiente', and 'Cancelar'.

Figura 12: Pantalla de configuración de entorno de procesamiento.

- **Nombre del proceso:** Elegiremos un nombre único para nuestro entorno.
- **Tipo de máquina virtual:** Seleccionaremos «CPU».
- **Tamaño de la máquina virtual:** En este caso, seleccionaremos la más pequeña, dado que se trata de una simple demostración: Standard_DS11_v2.

Una vez configurado esto, podemos dar clic en «Revisar y crear» y finalmente en «Crear».

Creación de instancias de proceso ×

✓ Valores obligatorios

✓ Programación
opcional

✓ Seguridad
opcional

✓ Aplicaciones
opcional

✓ Etiquetas
opcional

④ Revisar

Revisar

Revise o realice cambios en el trabajo antes del envío. [Descargue una plantilla para la automatización.](#)

Valores obligatorios

Revisar

Nombre del proceso	Máquina virtual
AzureML-compute-MNA-OEGG	Standard_DS11_v2
Tipo de máquina virtual	2 núcleos, 14 GB de RAM, 28 GB de almacenamiento
CPU	

Programación

Revisar

ⓘ Apagado automático habilitado de forma predeterminada

Apagado automático	Programación de inicio y apagado
Después de 60 minutos de inactividad	--

Seguridad

Revisar

Habilitar SSH	Habilitar SSO
no	sí
Habilitar red virtual	Habilitación de la identidad administrada
no	no
Deshabilitar el acceso raíz	
sí	

Aplicaciones

Revisar

Crear

Atrás

Cancelar

Figura 13: Pantalla de creación de entorno de procesamiento.

Una vez que se haya terminado de crear nuestro «entorno», podremos seleccionarlo en la sección «proceso» de nuestro cuaderno de trabajo y una vez que se muestre que está en ejecución, podremos probarlo ejecutando algún código simple de Python.




Figura 14: Cuaderno de trabajo con entorno seleccionado y activo.



Figura 15: Código Python de ejemplo, ejecutado en nuestro cuaderno de trabajo.

2.3. Carga de datos

Una vez que hayamos comprobado que nuestro entorno funciona correctamente, procederemos a realizar una carga de datos, a partir de un archivo previamente descargado (weatherAUS.csv), correspondiente a los registros de clima en Australia. Para ello, nos dirigiremos a la sección de «Datos», que se encuentra debajo de «Recursos», en la barra lateral izquierda.

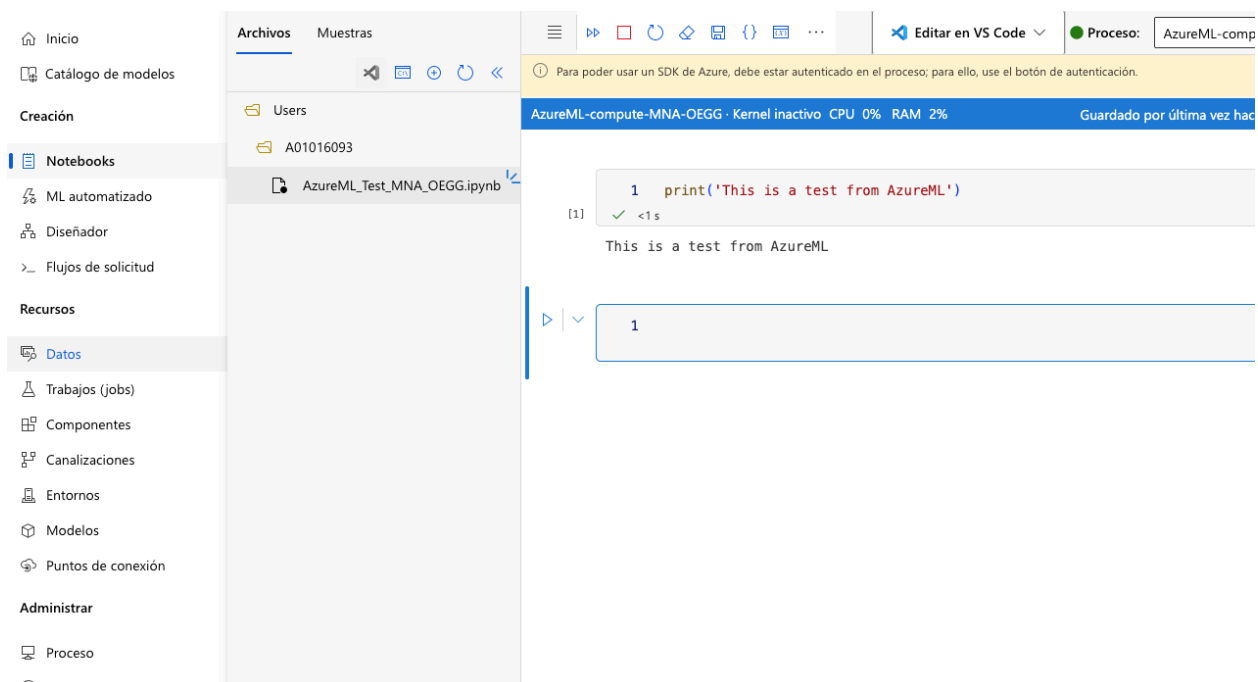


Figura 16: Menú de Datos, dentro de la barra lateral de nuestro cuaderno de trabajo.

Una vez que demos clic, entraremos a una nueva pantalla de recursos de datos. Una vez ahí, daremos clic en «+ Crear» para iniciar con la definición de nuestro origen de datos.




Figura 17: Creación de recurso de datos.

Al dar clic, se nos abrirá una nueva pantalla de configuración, donde definiremos lo siguiente:

Crear recurso de datos

1 Tipo de datos

2 Origen de datos

Establecer el nombre y el tipo del recurso de datos

Los clientes no deben incluir datos personales ni otra información confidencial en los campos marcados con el porque el contenido de estos campos se puede registrar y compartir en sistemas de Microsoft para facilitar las operaciones y la solución de problemas. [Más información](#)

Nombre *

Australian_Rain

Descripción

Dataset with information about the amount of rain in Australia

Tipo *

Archivo (uri_file)

Atrás

Siguiente

Cancelar

Casos de uso para tipos de datos

¿Cuándo debo usar el tipo archivo?
El tipo Archivo se recomienda en la mayoría de los escenarios cuando se trabaja con un único archivo de datos de cualquier tipo (incluidos los datos tabulares). Este tipo permite especificar una ubicación de archivo por URI en una ubicación de almacenamiento en el equipo local, un almacén de datos adjunto, un almacenamiento blob/ADLS o una ubicación http(s) disponible públicamente. Hay muchos tipos de URI admitidos. En la CLI de Azure Machine Learning v2 o SDK de Python v2, este tipo de datos se denomina uri_file. [Más información sobre el tipo uri_file](#)

¿Cuándo debo usar el tipo carpeta?
El tipo Carpeta tiene todas las mismas capacidades y casos de uso que el tipo Archivo, pero se usa al especificar una ubicación de carpeta. En la CLI de Azure Machine Learning v2 o el SDK de Python v2, este tipo de datos se denomina uri_folder. [Más información sobre el tipo uri_folder](#)

¿Cuándo debo usar el tipo tabla?
El tipo Tabla es más útil para escenarios avanzados en los que es posible que deba abstraer la definición de esquema para facilitar el uso compartido. Debe usarlo cuando tenga transformaciones complejas y esquemas que quiera capturar en un recurso reutilizable. Para datos tabulares más sencillos, se recomiendan los tipos Archivo y Carpeta. Si elige el tipo Tabla, en la CLI de Azure Machine Learning v2 o el SDK de Python v2, este tipo de datos se denomina mitable. [Más información sobre el tipo mitable](#)

Figura 18: Pantalla de configuración de recurso de datos.

- **Nombre:** Definiremos un nuevo nombre para nuestro recurso de datos.
- **Descripción:** Definiremos una descripción para nuestro recurso de datos.
- **Tipo:** Seleccionaremos «Archivo (uri_file)» para nuestro caso de uso.

Después, en la siguiente sección: Origen de datos, seleccionaremos la opción «De archivos locales» y daremos clic en «Siguiente».

Crear recurso de datos

Tipo de datos

Origen de datos

Tipo de almacenamiento de destino

Selección de archivo

Revisar

Elegir un origen para el recurso de datos

Elija el origen de datos desde el que desea crear el recurso. Un origen de datos puede ser de una ubicación de almacenamiento local del equipo, de un almacén de datos adjunto, de Azure Storage o de una ubicación web disponible públicamente.

Desde un URI

Cree un recurso de datos proporcionando una dirección URL web o un URI que represente una ruta de acceso a los datos.

Desde Azure Storage

Cree un recurso de datos a partir de servicios de almacenamiento de datos registrados, incluidos Azure Blob Storage, el recurso compartido de archivos de Azure y Azure Data Lake.

De archivos locales

Cree un recurso de datos cargando archivos desde la unidad local.

Atrás

Siguiente

Cancelar

Figura 19: Elegir el origen para el recurso de datos.

En la siguiente pantalla, seleccionaremos el almacén de datos «workspaceblobstore», que fue el almacén que se creó al inicializar nuestro espacio de trabajo en Azure ML.

Crear recurso de datos

Tipo de datos

Origen de datos

Tipo de almacenamiento de destino

Selección de archivo

Revisar

Seleccionar un almacén de datos

Elija un tipo de almacenamiento y un almacén de datos al que cargar sus datos en el siguiente paso. También puede crear primero un nuevo almacén de datos para sus datos.

Tipo de almacén de datos *

Azure Blob Storage

Crear nuevo almacén de datos

Buscar almacén de dat

Filtrar

Columnas

Nombre ↓	Nombre de almacenamiento	Fecha de creación
☒ workspaceblobstore	azuremlmna7567012943	Mar 14, 2026 7:06 PM
workspaceartifactstore	azuremlmna7567012943	Mar 14, 2026 7:06 PM

<< < Página 1 de 1 > >> 25/Página

Atrás Siguiente Cancelar

Figura 20: Seleccionar nuestro almacén de datos.

Posteriormente, en la sección «Selección de archivo», podremos cargar nuestro archivo previamente descargado con el botón «Crear archivo» y seleccionando el archivo desde nuestra computadora. Una vez que se haya completado la carga, podemos dar clic en «Siguiente».

Crear recurso de datos

Tipo de datos

Origen de datos

Tipo de almacenamiento de destino

Selección de archivo

Revisar

Elegir un archivo

Elija un archivo para cargarlo desde la unidad local. Con el tipo de uri_file, debe cargar un único archivo.

Ruta de acceso de carga

azureml://subscripti...

Cargar archivo

☐ Sobrescribir si ya existe

Cargar lista

weatherAUS.csv	13.44 MB/13.44 MB	...
----------------	-------------------	-----

Información

¿Qué tipos de archivo puedo usar?

Los tipos de archivo admitidos son los siguientes: delimitado (es decir, CSV o TSV), Parquet, JSON Lines y texto sin formato.

¿Dónde se cargan los archivos?

Los archivos se cargarán en el almacén de datos seleccionado y estarán disponibles en el área de trabajo.

Atrás

Siguiente

Cancelar

Figura 21: Carga de nuestro archivo de datos.

Finalmente podemos revisar el resumen de la configuración de nuestro recurso de datos y dar clic en «Crear».

Crear recurso de datos

Tipo de datos

Origen de datos

Tipo de almacenamiento de destino

Selección de archivo

Revisar

Revisar

Revise la configuración del recurso de datos y realice los cambios necesarios.

Tipo de datos

Nombre
Australian_Rain

Descripción
Dataset with information about the amount of rain in Australia

Tipo
uri_file

Origen de datos

Tipo
Local

Selección de archivo

Ruta de acceso de carga
azureml://subscriptions/fed43134-b04d-48bd-9789-21a25144c37/resourcegroups/gr-machinelearning/workspaces/azureml-mna/datastores/workspaceblobstore/paths/UI/2026-03-15_012234_UTC/weatherAUS.csv

Archivos cargados
weatherAUS.csv

Almacenamiento

Tipo de almacén de datos
AzureBlob

Nombre del almacén de datos
workspaceblobstore

Atrás

Crear

Cancelar

Figura 22: Creación de nuestro recurso de datos.

Una vez creado nuestro recurso de datos, se nos mostrará la pantalla de información, donde podremos realizar varias acciones.

Microsoft Foundry | Azure Machine Learning

Instituto Tecnológico y de Estudios Superiores de Monterrey > azureml-mna > Datos > Australian_Rain

Todas las áreas de trabajo

Inicio

Catálogo de modelos

Creación

Recursos

Administrar

Australian_Rain

Version: 1 (más reciente)

Detalles Consumir Explorar Trabajos

Nueva versión Actualizar Archivar Restaurar

Atributos

Tipo
Archivo (uri_file)

URI de activo con nombre
azureml:Australian_Rain:1

Autor
Oscar Enrique García García

Versión actual
1

Última versión
1

Hora de creación
Mar 14, 2026 7:23 PM

Hora de modificación
Mar 14, 2026 7:23 PM

Etiquetas

Sin etiquetas

Descripción

Dataset with information about the amount of rain in Australia

Orígenes de datos

Almacén de datos
workspaceblobstore

Ruta de acceso relativa
UI/2026-03-15_012234_UTC/weatherAUS.csv

URI de almacén de datos
azureml://subscriptions/fed43134-b04d-48bd-9789-...

Acciones
Ver en la exploración de almacenes de datos
Ver en Azure Portal

Identificador URI de almacenamiento
https://azuremlmna7567012943.blob.core.windows...

Figura 23: Pantalla de información de nuestro recurso de datos.

1. En la pestaña «Explorar» podremos tener una previsualización de nuestros datos cargados.

Australian_Rain Versión: 1 (más reciente) ▾

Detalles Consumir **Explorar** Trabajos

Actualizar

Vista previa

Path	File Name	Modified Time	Created Time	File Size	File Format	CanSeek
/UI/2026-03-15_01223...	weatherAUS.csv	2026-03-15 01:23:07	2026-03-15 01:23:07	14094055	.csv	true

Vista previa
Mostrando el primer 0.1 MiB de datos de origen.

Mostrar como cuadrícula ☒ Con encabezados de columna ☐

Column1	Column2	Column3	Column4	Column5	Column6	
Date	Location	MinTemp	MaxTemp	Rainfall	Evapora...	S
2008-12...	Albury	13.4	22.9	0.6	NA	h
2008-12...	Albury	7.4	25.1	0	NA	h
2008-12...	Albury	12.9	25.7	0	NA	h
2008-12...	Albury	9.2	28	0	NA	h
2008-12...	Albury	17.5	32.3	1	NA	h
2008-12...	Albury	14.6	29.7	0.2	NA	h
2008-12...	Albury	14.3	25	0	NA	h
2008-12...	Albury	7.7	26.7	0	NA	h
2008-12...	Albury	9.7	31.9	0	NA	h
2008-12...	Albury	13.1	30.1	1.4	NA	h

Figura 24: Pantalla de previsualización de datos.

2. En la pestaña «Consumir», podremos ver un ejemplo de código en Python, que nos permitirá consultar nuestros datos cargados. Por ahora, copiaremos este código, ya que lo utilizaremos posteriormente para consumir nuestros datos.




Figura 25: Pantalla de consumo de datos.

2.4. Ejecución de código en cuaderno de trabajo y análisis de datos

Una vez que copiamos el código Python de la pestaña «Consumir», regresaremos a nuestra cuaderno de trabajo dando clic en «Notebooks», en la barra lateral izquierda y, una vez en nuestro cuaderno de trabajo, pegaremos nuestro código y lo ejecutaremos.




Figura 26: Ejecución de código en nuestro cuaderno de trabajo

Una vez terminada la ejecución, podremos ver nuestro dataframe con nuestros datos cargados, desde el archivo que subimos anteriormente. De esta forma, podemos comprobar que nuestro archivo se cargó correctamente y podemos empezar con la manipulación y/o análisis de los datos.

	Date	Location	MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine	WindGustDir	WindGustSpeed	WindDir9am	...	Humidity9am	Humidity3pm	Pressure9am	Pressure3pm	Cloud9am	Cloud3pm	Ter
0	2008-12-01	Albury	13.4	22.9	0.6	NaN	NaN	W	44.0	W	...	71.0	22.0	1007.7	1007.1	8.0	NaN	
1	2008-12-02	Albury	7.4	25.1	0.0	NaN	NaN	WNW	44.0	NNW	...	44.0	25.0	1010.6	1007.8	NaN	NaN	
2	2008-12-03	Albury	12.9	25.7	0.0	NaN	NaN	WSW	46.0	W	...	38.0	30.0	1007.6	1008.7	NaN	2.0	
3	2008-12-04	Albury	9.2	28.0	0.0	NaN	NaN	NE	24.0	SE	...	45.0	16.0	1017.6	1012.8	NaN	NaN	
4	2008-12-05	Albury	17.5	32.3	1.0	NaN	NaN	W	41.0	ENE	...	82.0	33.0	1010.8	1006.0	7.0	8.0	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
145455	2017-06-21	Uluru	2.8	23.4	0.0	NaN	NaN	E	31.0	SE	...	51.0	24.0	1024.6	1020.3	NaN	NaN	
145456	2017-06-22	Uluru	3.6	25.3	0.0	NaN	NaN	NNW	22.0	SE	...	56.0	21.0	1023.5	1019.1	NaN	NaN	
145457	2017-06-23	Uluru	5.4	26.9	0.0	NaN	NaN	N	37.0	SE	...	53.0	24.0	1021.0	1016.8	NaN	NaN	
145458	2017-06-24	Uluru	7.8	27.0	0.0	NaN	NaN	SE	28.0	SSE	...	51.0	24.0	1019.4	1016.5	3.0	2.0	
145459	2017-06-25	Uluru	14.9	NaN	0.0	NaN	NaN	NaN	NaN	ESE	...	62.0	36.0	1020.2	1017.9	8.0	8.0	

Figura 27: Dataframe resultante con datos del clima en Australia

A continuación se muestran algunas cosas y conclusiones a las que se llegó, basado en este análisis de datos.

1. Se importaron las librerías

Importación de librerías

```
1 %pip install seaborn
```

[3] ✓ 1 sec

Requirement already satisfied: contourpy>=1.0.1 in /anaconda/envs/azureml_py310_sdkv2/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (1.3.2)

Requirement already satisfied: cycler>=0.10 in /anaconda/envs/azureml_py310_sdkv2/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (0.12.1)

Requirement already satisfied: fonttools>=4.22.0 in /anaconda/envs/azureml_py310_sdkv2/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (4.61.1)

Requirement already satisfied: kiwisolver>=1.3.1 in /anaconda/envs/azureml_py310_sdkv2/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (1.4.9)

Requirement already satisfied: packaging>=20.0 in /anaconda/envs/azureml_py310_sdkv2/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (25.0)

Requirement already satisfied: pillow>=8 in /anaconda/envs/azureml_py310_sdkv2/lib/python3.10/site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (12.1.0)

...

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 from sklearn.experimental import enable_iterative_imputer
6 from sklearn.impute import IterativeImputer
7 from sklearn.preprocessing import LabelEncoder
```

[4] ✓ 1 sec

Figura 28: Importación de librerías para EDA

2. Se hizo una impresión de estadísticas descriptivas iniciales y de la estructura del dataset

Manejo exploratorio de datos

Estructura del dataset

```
1 print(df.info())
```

[5] ✓ <1 sec

```
... 10 WindDir3pm      141232 non-null object
    11 WindSpeed9am   143693 non-null float64
    12 WindSpeed3pm   142398 non-null float64
    13 Humidity9am     142806 non-null float64
    14 Humidity3pm     140953 non-null float64
    15 Pressure9am     130395 non-null float64
    16 Pressure3pm     130432 non-null float64
    17 Cloud9am        89572 non-null float64
    18 Cloud3pm        86102 non-null float64
    19 Temp9am         143693 non-null float64
    20 Temp3pm         141851 non-null float64
    21 RainToday       142199 non-null object
    22 RainTomorrow    142193 non-null object
dtypes: float64(16), object(7)
memory usage: 25.5+ MB
None
```

Estadísticas descriptivas

```
1 print(df.describe())
```

[6] ✓ <1 sec

	MinTemp	MaxTemp	Rainfall	Evaporation \
count	143975.000000	144199.000000	142199.000000	82670.000000
mean	12.194034	23.221348	2.360918	5.468232
std	6.398495	7.119049	8.478060	4.193704
min	-8.500000	-4.800000	0.000000	0.000000
25%	7.600000	17.900000	0.000000	2.600000
50%	12.000000	22.600000	0.000000	4.800000
75%	16.900000	28.200000	0.800000	7.400000
max	33.900000	48.100000	371.000000	145.000000

	Sunshine	WindGustSpeed	WindSpeed9am	WindSpeed3pm \
count	75625.000000	135197.000000	143693.000000	142398.000000
mean	7.611178	40.035230	14.043426	18.662657
std	3.785483	13.607062	8.915375	8.809800
min	0.000000	6.000000	0.000000	0.000000
25%	4.800000	21.000000	7.000000	12.000000

Figura 29: Impresión de estadísticas descriptivas y estructura del dataset.

3. Se hicieron conversiones iniciales de datos, así como conteo de nulos por campo.

Limpieza inicial

```
[7] 1 # Convertir fecha
    2 df['Date'] = pd.to_datetime(df['Date'])
    3 df['Month'] = df['Date'].dt.month # Se agrega una columna de Mes a partir de la fecha para detectar
    ✓ <1 sec
```

Análisis de valores faltantes

```
> | ✓ [8] 1 missing_values = df.isnull().sum()
    2 missing_percentage = (missing_values / len(df)) * 100
    3 print("\n--- Porcentaje de valores nulos por columna ---")
    4 print(missing_percentage.sort_values(ascending=False))
    ✓ <1 sec
```

...

```
--- Porcentaje de valores nulos por columna ---
Sunshine      48.009762
Evaporation   43.166506
Cloud3pm      40.807095
Cloud9am      38.421559
Pressure9am    10.356799
Pressure3pm    10.331363
WindDir9am     7.263853
WindGustDir    7.098859
WindGustSpeed  7.055548
Humidity3pm    3.098446
WindDir3pm     2.906641
Temp3pm        2.481094
RainTomorrow   2.245978
RainToday      2.241852
```

Figura 30: Conteo de nulos en el dataset.

4. Se hizo una preparación de datos, que incluye una conversión de variables categóricas a «numéricas», así como una imputación sobre los valores faltantes.

Preparación de los datos

```
[31] 1 # Eliminamos filas donde la variable objetivo es nula para evitar ruido
      2 df = df.dropna(subset=['RainTomorrow']).copy()
      ✓ <1 sec
```

```
[33] 1 #Creamos nuevas columnas para "abanderar" los registros que tienen nulos para alguna de las 4 colum
      2 cols_high_null = ['Sunshine', 'Evaporation', 'Cloud3pm', 'Cloud9am']
      3 for col in cols_high_null:
      4     df[col + '_was_missing'] = df.loc[:,col].isnull().astype(int)
      ✓ <1 sec
```

```
[34] 1 #Preparación para la imputación:
      2
      3 le = LabelEncoder()
      4 categorical_cols = ['Location', 'WindGustDir', 'RainToday', 'RainTomorrow']
      5 for col in categorical_cols:
      6     df[col] = le.fit_transform(df[col].astype(str))
      ✓ <1 sec
```

```
[35] 1 # Seleccionamos las columnas numéricas para el proceso de imputación
      2 # Excluimos la fecha
      3 df_numeric = df.select_dtypes(include=[np.number])
      ✓ <1 sec
```

```
[36] 1 # 5. Aplicación de Imputación Avanzada (MICE)
      2 print("Iniciando imputación avanzada...")
      3 imputer = IterativeImputer(max_iter=10, random_state=42)
      4 df_imputed_values = imputer.fit_transform(df_numeric)
      ✓ 1 min 11 sec
```

Iniciando imputación avanzada...
/anaconda/envs/azureml_py310_sdkv2/lib/python3.10/site-packages/sklearn/impute/_iterative.py:895:
ConvergenceWarning: [IterativeImputer] Early stopping criterion not reached.
warnings.warn()

```
[37] 1 # Convertimos el resultado de vuelta a un DataFrame
      2 df_final = pd.DataFrame(df_imputed_values, columns=df_numeric.columns)
      ✓ <1 sec
```

Figura 31: Preparación de datos.

- Se implementó código para graficar algunas variables en boxplots, tener una matriz de correlación, gráficos de estacionalidad, etc.

The screenshot shows an AzureML notebook titled 'AzureML_Test_MNA'. The interface includes a top bar with navigation links, a toolbar with icons for running, saving, and editing, and a status bar indicating the kernel is idle. The main area contains a code cell with the following Python code:

```

1 plt.figure(figsize=(6, 4))
2 sns.countplot(x='RainTomorrow', data=df_final, palette='viridis')
3 plt.title('Distribución de RainTomorrow (Target)')
4 plt.show()
5
6 # Histogramas de variables numéricas clave
7 numerical_cols = ['MinTemp', 'MaxTemp', 'Rainfall', 'Humidity3pm', 'Pressure3pm']
8 df_final[numerical_cols].hist(figsize=(12, 10), bins=30, color='skyblue', edgecolor='black')
9 plt.tight_layout()
10 plt.show()
11
12 # 6. Análisis Bivariado
13 # Matriz de correlación
14 plt.figure(figsize=(12, 10))
15 corr_matrix = df_final.select_dtypes(include=[np.number]).corr()
16 sns.heatmap(corr_matrix, annot=True, fmt=".2f", cmap='coolwarm', square=True)
17 plt.title('Matriz de Correlación de Variables Meteorológicas')
18 plt.show()
19
20 # Relación entre Humedad y Lluvia mañana (Boxplot)
21 plt.figure(figsize=(8, 5))
22 sns.boxplot(x='RainTomorrow', y='Humidity3pm', data=df_final, palette='Set2')
23 plt.title('Humedad a las 3pm vs Predicción de Lluvia')
24 plt.show()
25
26 # Análisis de estacionalidad
27 plt.figure(figsize=(12, 10))
28 sns.lineplot(data=df, x='Month', y='Rainfall')
29 plt.title('Estacionalidad')
30 plt.show()
31

```

At the bottom of the code cell, it shows '[38] ✓ 8 sec', indicating the code was executed successfully in 8 seconds.

Figura 32: Código para visualización de datos.

2.4.1. Hallazgos del análisis de los datos

1. Existen 4 variables con un alto número de nulos: Sunshine, Evaporation, Cloud3pm y Cloud9am.
2. Existe un desbalanceo de clases, para nuestra variable objetivo, en nuestros datos. Esto puede ocasionar que nuestro modelo sea muy bueno «prediciendo» que no va a llover; para ello, tenemos que elegir correctamente nuestras métricas de desempeño.

3. Existen algunas variables (e.g. Rainfall) con un claro sesgo que debería ser corregido con alguna transformación (e.g. logarítmica).
4. Hay algunas variables con alto índice de correlación. Esto implicará que el DS quizás decida eliminar algunas variables para el modelo final (e.g. Elegir entre MaxTemp/Min Temp y Temp9am/Temp3pm)
5. La humedad de las 3pm tiene una alta correlación con la probabilidad de lluvia de «mañana», lo que también nos podría dar grandes inicios al momento de seleccionar nuestras variables predictoras.
6. Hay unos meses donde los casos de lluvia son claramente mayores; esto nos podría mostrar casos de estacionalidad.




Figura 33: Desbalanceo de clases en los datos.




Figura 34: Histogramas para variables.




Figura 35: Matriz de correlación.




Figura 36: Humedad 3pm vs Predicción de lluvia.




Figura 37: Estacionalidad.

3. Investigación de proceso de Azure AutoML

A continuación se describirá de manera general qué es «AutoML», cuáles son sus beneficios y cómo configurarlo dentro de Azure ML.

3.1. ¿Qué es AutoML?

Azure AutoML (Machine Learning Automatizado) es una funcionalidad dentro de Azure Machine Learning diseñada para agilizar el proceso de creación de modelos de aprendizaje automático.

En lugar de que un científico de datos pruebe manualmente cada algoritmo y ajuste cada hiperparámetro, AutoML lo hace de forma automática. Es como tener un «asistente experto» que «entrena» cientos de combinaciones para encontrar la mejor para tus datos.

Tradicionalmente, el ciclo de vida de ML requiere mucho tiempo en tareas repetitivas. AutoML se encarga de:

- **Selección del Algoritmo:** Prueba desde modelos lineales simples hasta redes neuronales o algoritmos de boosting (como XGBoost o LightGBM).
- **Ingeniería de Características (Featurization):** Maneja automáticamente los valores nulos, realiza codificación de variables categóricas y escala los datos numéricos.
- **Ajuste de Hiperparámetros:** Encuentra la configuración óptima para maximizar la precisión.
- **Validación:** Aplica técnicas como validación cruzada para asegurar que el modelo sea robusto y no solo memorice los datos.

Actualmente, Azure AutoML está optimizado para tres tareas principales:

- **Clasificación:** Como nuestro caso de «lluvia» (¿Sí o No?), detección de fraude o diagnóstico médico.

- **Regresión:** Predecir valores numéricos, como el precio de una casa o la demanda de energía.
- **Pronóstico de Series de Tiempo (Forecasting):** Predecir valores futuros basados en datos históricos, considerando tendencias y estacionalidad (ej. ventas del próximo mes).

3.2. Configuración del servicio y carga de datos

Para crear un nuevo trabajo de AutoML, es necesario entrar al mismo servicio de la sección anterior: Azure ML. Dentro de Azure ML, procederemos a ir a la sección «ML automatizado».

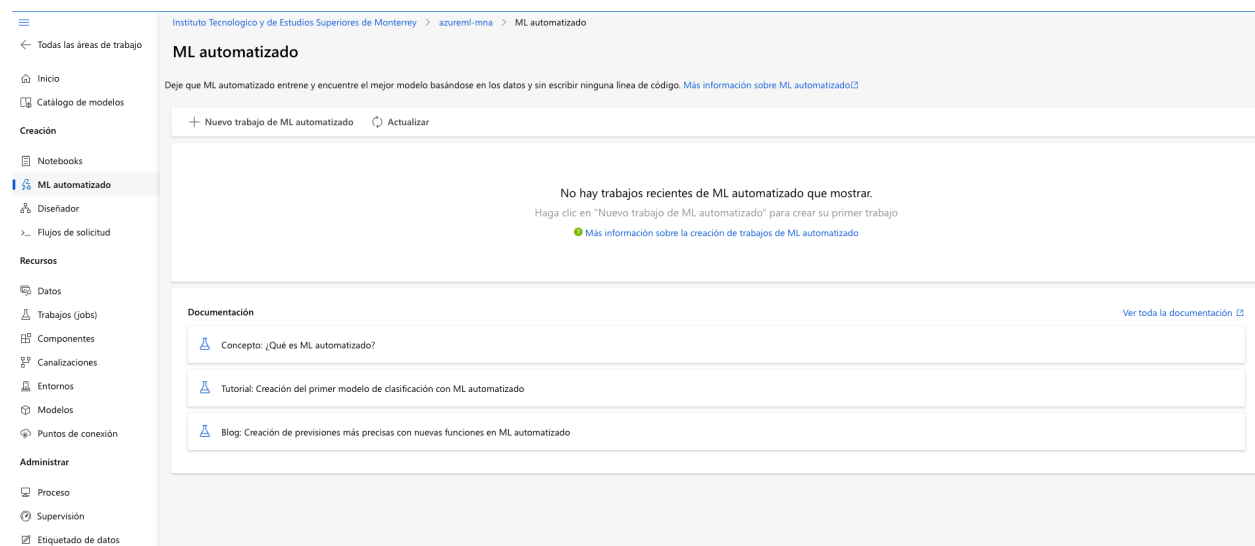


Figura 38: Pantalla de ML automatizado.

Al entrar a la sección de «ML automatizado», procederemos dar clic al botón «+ Nuevo trabajo de ML automatizado».

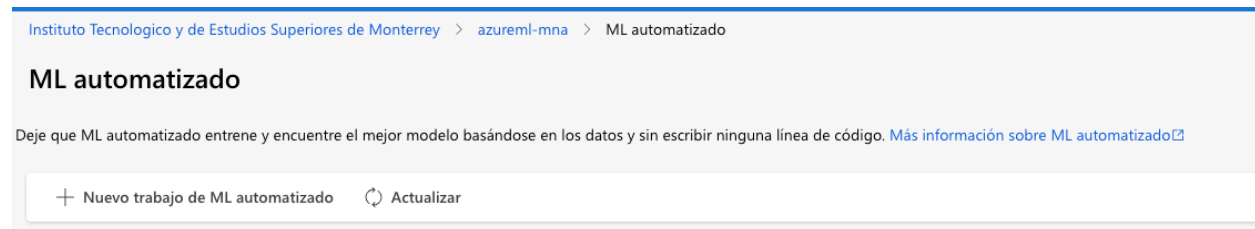


Figura 39: Nuevo trabajo de ML automatizado.

Al dar clic en el botón, se nos abrirá una nueva pantalla de configuración, donde podremos definir el nombre del trabajo, el nombre del experimento, la descripción y las etiquetas.

The screenshot displays the 'Envío de un trabajo de ML automatizado' configuration page. On the left is a vertical sidebar with a progress indicator showing five steps: 'Método de entrenamiento' (completed), 'Configuración básica' (active), 'Tipo de tarea y datos', 'Configuración de tarea', 'Proceso', and 'Revisión'. The main content area is titled 'Configuración básica' and includes the instruction 'Comencemos con información básica sobre el trabajo de entrenamiento.' It contains several input fields: 'Nombre del trabajo *' with the value 'AutomatedML-OEGG', 'Nombre del experimento *' with radio buttons for 'Seleccionar existente' and 'Crear nuevo' (selected), and 'Nombre del experimento nuevo *' with the value 'Default'. There is also a 'Descripción' text area. At the bottom, there is an 'Etiquetas' section with a table-like structure showing 'Nombre' and 'Valor' columns, and an 'Agregar' button. At the very bottom of the page are three buttons: 'Atrás', 'Siguiente', and 'Cancelar'.

Figura 40: Configuración general de trabajo de AutoML.

En secciones siguientes, dentro de la misma pantalla, también podremos seleccionar nuestro almacén de datos, así como cargar, configurar y revisar nuestro origen de datos (e.g. nuestro archivo de clima de Australia), de forma muy similar a como lo hicimos en la libreta de la sección anterior.

Crear recurso de datos

Tipo de datos

Origen de datos

Tipo de almacenamiento de destino

Selección de MLTable

Revisar

Seleccionar un almacén de datos

Elija un tipo de almacenamiento y un almacén de datos al que cargar sus datos en el siguiente paso. También puede crear primero un nuevo almacén de datos para sus datos.

Tipo de almacén de datos *

Azure Blob Storage

Crear nuevo almacén de datos

Buscar almacén de dat

Nombre ↓	Nombre de almacenamiento	Fecha de creación
workspaceblobstore	azuremlmna7567012943	Mar 14, 2026 7:06 PM
workspaceartifactstore	azuremlmna7567012943	Mar 14, 2026 7:06 PM

<< < Página 1 de 1 > >> 25/Página

Atrás Siguiente Cancelar

Figura 41: Selección de almacén de datos.

Instituto Tecnológico y de Estudios Superiores de Monterrey > azureml-mna > Trabajo de aprendizaje

Envío de un trabajo de ML automatizado

Método de entrenamiento

Configuración básica

Tipo de tarea y datos

Configuración de tarea

Proceso

Revisión

Tipo de tarea y datos

Elija el tipo de tarea que realice el modelo y los datos que se van a usar para el entrenamiento. Más información

Seleccionar el tipo de tarea *

Clasificación

Seleccionar datos

Asegúrese de que los datos están preprocesados en un formato compatible.

+ Crear Actualizar

Mostrar solo los recursos de datos admitidos Restablecer vista

Buscar

Nombre	Tipo	Fecha de creación	Fecha de modificación
No hay datos existentes			

<< < Página 1 de 1 > >> 25/Página

Atrás Siguiente Cancelar

Figura 42: Carga de datos nuevos. Botón «+ Crear».

Crear recurso de datos

Tipo de datos

Origen de datos

Establecer el nombre y el tipo del recurso de datos

Nombre *

Australian_Rain_AutoML

Descripción

Descripción del recurso de datos

Tipo *

Tabular

¿Cuándo debo usar el tipo archivo?

El tipo Archivo se recomienda en la mayoría de los escenarios cuando se trabaja con un único archivo de datos de cualquier tipo (incluidos los datos tabulares). Este tipo permite especificar una ubicación de archivo por URI en una ubicación de almacenamiento en el equipo local, un almacén de datos adjunto, un almacenamiento blob/ADLS o una ubicación http(s) disponible públicamente. Hay muchos tipos de URI admitidos. En la CLI de Azure Machine Learning v2 o SDK de Python v2, este tipo de datos se denomina uri_file. [Más información sobre el tipo uri_file](#)

¿Cuándo debo usar el tipo carpeta?

El tipo Carpeta tiene todas las mismas capacidades y casos de uso que el tipo Archivo, pero se usa al especificar una ubicación de carpeta. En la CLI de Azure Machine Learning v2 o el SDK de Python v2, este tipo de datos se denomina uri_folder. [Más información sobre el tipo uri_folder](#)

¿Cuándo debo usar el tipo tabla?

El tipo Tabla es más útil para escenarios avanzados en los que es posible que deba abstraer la definición de esquema para facilitar el uso compartido. Debe usarlo cuando tenga transformaciones complejas y esquemas que quiera capturar en un recurso reutilizable. Para datos tabulares más sencillos, se recomiendan los tipos Archivo y Carpeta. Si elige el tipo Tabla, en la CLI de Azure Machine Learning v2 o el SDK de Python v2, este tipo de datos se denomina mtable. [Más información sobre el tipo mtable](#)

Atrás

Siguiente

Cancelar

Figura 43: Configuración de origen de datos. En este caso, seleccionamos tipo Tabular, debido a la naturaleza del archivo.

Crear recurso de datos

Tipo de datos

Origen de datos

Tipo de almacenamiento de destino

Selección de archivos o carpetas

Configuración

Esquema

Revisar

Elegir un origen para el recurso de datos

Elija el origen de datos desde el que desea crear el recurso. Un origen de datos puede ser de una ubicación de almacenamiento local del equipo, de un almacén de datos adjunto, de Azure Storage o de una ubicación web disponible públicamente.

Desde Azure Storage

Cree un recurso de datos a partir de servicios de almacenamiento de datos registrados, incluidos Azure Blob Storage, el recurso compartido de archivos de Azure y Azure Data Lake.

Desde bases de datos SQL

Cree un conjunto de datos a partir de una base de datos de Azure SQL y una base de datos de Azure PostgreSQL.

Desde Azure Open Datasets

Cree un conjunto de datos con un solo clic a partir de conjuntos de datos predefinidos. Estos conjuntos de datos los crea el público general y se publican como Azure Open Datasets.

De archivos locales

Cree un recurso de datos cargando archivos desde la unidad local.

De archivos web

Cree un recurso de datos a partir de un único archivo ubicado en una dirección URL web pública.

Atrás

Siguiente

Cancelar

Figura 44: Selección de origen de datos.




Figura 45: Carga de nuestro archivo.

También se muestra una sección donde podemos configurar nuestro origen de datos, en cuanto a delimitadores, codificación, encabezados, etc.




Figura 46: Previsualización de datos cargados.

Asimismo, se muestra una pantalla donde podemos seleccionar nuestras columnas a utilizar (quizás resultado de un EDA anterior, como lo hicimos nosotros) así como el tipo de dato de cada columna.

Crear recurso de datos ×

✓ Tipo de datos

✓ Origen de datos

✓ Tipo de almacenamiento de destino

✓ Selección de archivos o carpetas

✓ Configuración

Esquema

● Revisar

Esquema

Los tipos de columna se detectan automáticamente en función del subconjunto inicial de los datos y se pueden actualizar aquí. Los valores que no se alineen con el tipo de columna especificado producirán un error de conversión y se rellenarán con valores nulos o se reemplazarán con un valor de error. Los errores de vista previa de las conversiones provocan bloqueos y es posible continuar.

Incluir	Nombre de columna	Tipo	Valores de ejemplo	Formato de fecha ⓘ	Propiedades ⓘ
☐	Path	Cadena		No aplicable al tipo seleccio...	No aplicable al ti... ▼
☒	Date	Fecha	2008-12-01 00:00:00, 2008-12-02 00:0...	%Y-%m-%d	Ninguno ▼
☒	Location	Cadena	Albury, Albury, Albury	No aplicable al tipo seleccio...	No aplicable al ti... ▼
☒	MinTemp	Decimal (punto '...' ▼)	13.4, 7.4, 12.9	No aplicable al tipo seleccio...	No aplicable al ti... ▼
☒	MaxTemp	Decimal (punto '...' ▼)	22.9, 25.1, 25.7	No aplicable al tipo seleccio...	No aplicable al ti... ▼
☒	Rainfall	Cadena	0.6, 0, 0	No aplicable al tipo seleccio...	No aplicable al ti... ▼
☒	Evaporation	Cadena	NA, NA, NA	No aplicable al tipo seleccio...	No aplicable al ti... ▼

Figura 47: Selección de columnas y tipos de datos.

Crear recurso de datos ×

✓ Tipo de datos

✓ Origen de datos

✓ Tipo de almacenamiento de destino

✓ Selección de archivos o carpetas

✓ Configuración

✓ Esquema

● Revisar

Revisar
Revise la configuración del recurso de datos y realice los cambios necesarios.

Tipo de datos ✎

Nombre
Australian_Rain_AutoML

Descripción
--

Tipo
tabular

Origen de datos ✎

Tipo
Local

Selección de archivo ✎

Ruta de acceso de carga
azureml://subscriptions/fed43134-b04d-48bd-9789-21a2514f4c37/resourcegroups/gr-machinelearning/workspaces/azureml-mna/datastores/workspaceblobstore/paths/UI/2026-03-15_013352_UTC/weatherAUS.csv

Archivos cargados
weatherAUS.csv

Almacenamiento ✎

Tipo de almacén de datos
AzureBlob

Esquema ✎

Date	Date
Location	String
MinTemp	Decimal
MaxTemp	Decimal
Rainfall	String

(mostrando 5 de 24 columnas)

Atrás Crear

Cancelar

Figura 48: Validación y revisión de origen de datos.

Una vez configurado nuestro origen de datos, se nos dará la opción de elegir nuestro tipo de tarea (en nuestro caso, Clasificación), los datos a utilizar (los que creamos en el paso anterior), el tipo de validación (cruzada, en nuestro caso), el número de validaciones, el porcentaje de datos de prueba, etc.

Instituto Tecnológico y de Estudios Superiores de Monterrey > azureml-mna > Trabajo de aprendizaje

Envío de un trabajo de ML automatizado

Método de entrenamiento

Configuración básica

Tipo de tarea y datos

Configuración de tarea

Proceso

Revisión

Tipo de tarea y datos

Correcto. El conjunto de datos Australian_Rain_AutoML se creó correctamente. Las listas pueden tardar unos segundos en actualizarse. Haga clic aquí para ir a este conjunto de datos.

Elija el tipo de tarea que desea que realice el modelo y los datos que se van a usar para el entrenamiento. [Más información](#)

Seleccionar el tipo de tarea *
Clasificación

Seleccionar datos
Asegúrese de que los datos están preprocesados en un formato compatible.

+ Crear

Actualizar

Mostrar solo los recursos de datos admitidos

Restablecer vista

Nombre	Tipo	Fecha de creación	Fecha de modificación
Australian_Rain_AutoML	Tabla	Mar 14, 2026 7:35 PM	Mar 14, 2026 7:35 PM

<< < Página 1 de 1 > >> 25/Página

Atrás

Siguiente

Cancelar

Figura 49: Selección de tipo de tarea y origen de datos.

Instituto Tecnológico y de Estudios Superiores de Monterrey > azureml-mna > Trabajo de aprendizaje

Envío de un trabajo de ML automatizado

Método de entrenamiento

Configuración básica

Tipo de tarea y datos

Configuración de tarea

Proceso

Revisión

Configuración de tarea

Columna de destino *
RainTomorrow (String)

Configuración de clasificación
☐ Activación del aprendizaje profundo
[Ver opciones de configuración adicionales](#) [Ver configuración de caracterización](#)

> Límites

Validar y probar
Puede elegir un tipo de validación y seleccionar datos de prueba como un paso opcional.
Tipo de validación
Validación cruzada k-fold
Número de validaciones cruzadas *
2
Datos de prueba
División de datos de entrenamiento y pruebas
Prueba porcentual de datos *
30

Atrás

Siguiente

Figura 50: Configuración de la clasificación.

Finalmente, podremos configurar nuestra máquina virtual y proceso, de la siguiente forma:

Instituto Tecnológico y de Estudios Superiores de Monterrey > azureml-mna > Trabajo de aprendizaje

Envío de un trabajo de ML automatizado

Método de entrenamiento

Configuración básica

Tipo de tarea y datos

Configuración de tarea

Proceso

Revisión

Proceso

Seleccione y configure el recurso de proceso para ejecutar el trabajo de entrenamiento.

Seleccionar un tipo de proceso

Sin servidor

Tipo de máquina virtual ⓘ

☒ CPU ☐ GPU

Nivel de máquina virtual ⓘ

☒ Dedicado ☐ Prioridad baja

Tamaño de la máquina virtual

Standard_DS3_v2 (núcleos: 4, 14 GB RAM, 28 GB de almacenamiento, 0.28 USD/h)

Número de instancias

1

Atrás Siguiente

Figura 51: Configuración del proceso y máquina virtual.

Envío de un trabajo de ML automatizado

✓ Método de entrenamiento

✓ Configuración básica

✓ Tipo de tarea y datos

✓ Configuración de tarea

✓ Proceso

④ Revisión

Revisión

Revise o realice cambios en el trabajo antes del envío.

Configuración básica

Nombre
AutomatedML-OEGG

Nombre del experimento
Default

Tiempo de espera (horas)
--

Tipo de tarea y datos

Tipo de tarea
Clasificación

Datos
Australian_Rain_AutoML

Configuración de tarea

Columna de destino
RainTomorrow

Activación del aprendizaje profundo
No

Validar tipo
Validación cruzada k-fold

Número de validaciones cruzadas
2

Tamaño del paso de validaciones cruzadas
--

Datos de prueba
División de datos de entrenamiento y pruebas

Prueba porcentual de datos
30

Configuración del proceso

Tipo de proceso
Proceso sin servidor de Azure ML

Tamaño de la máquina virtual
Standard_DS11_v2

Recuento de instancias
1

Atrás

Enviar trabajo de aprendizaje

Figura 52: Pantalla de revisión de nuestro trabajo de ML automatizado.

Una vez terminado este proceso, podremos ver nuestro nuevo trabajo de ML listado en la página inicial. Podremos ver también, que se encuentra en un estado «En ejecución» (así permanecerá hasta que termine el trabajo completo, que dependerá de los modelos, los datos, las validaciones configuradas, etc.). Nota: Tener en cuenta que este proceso puede durar horas, dependiendo nuestra configuración.

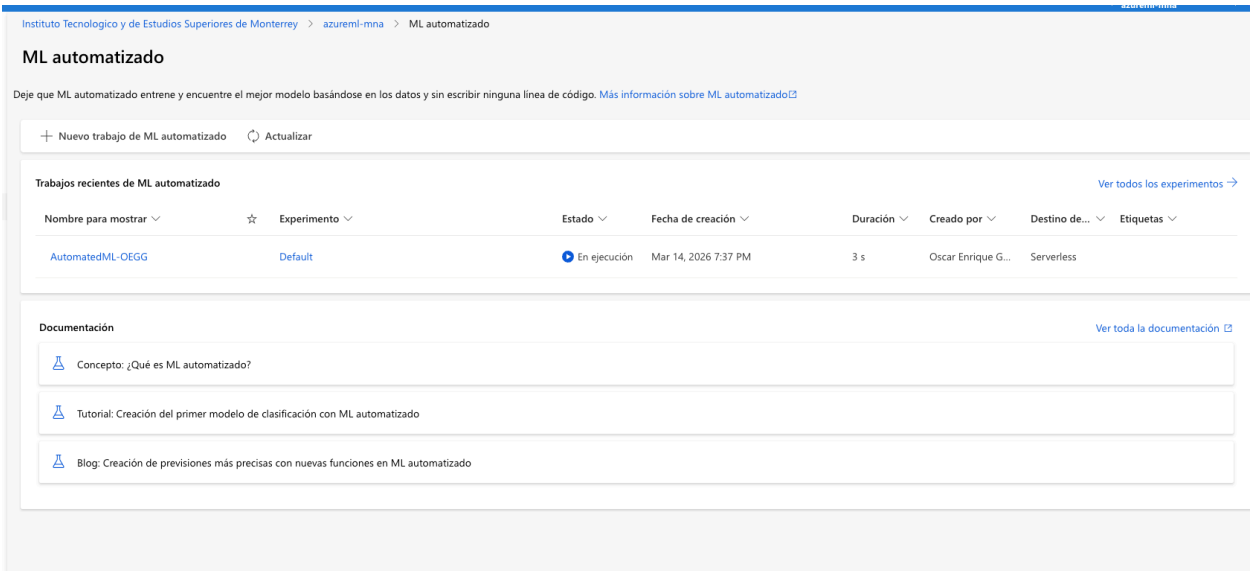


Figura 53: Nuevo trabajo de ML automatizado - En ejecución.

3.3. Resultados

Una vez completo nuestro proceso, podremos ver que el estatus cambia a «Completado».




Figura 54: Nuevo trabajo de ML automatizado - Completado.

Y, una vez completado, podremos ver diferentes cosas:

1. Insights interesantes sobre los datos: equilibrio de clases, valores nulos, cardinalidades, etc. En nuestro caso, como ya lo habíamos mencionado en la sección anterior, tenemos un problema de desbalanceo, así como de valores faltantes.

Tipo	Estado	Descripción
Detección del equilibrio de clases	Alerta	Se han detectado clases con desequilibrios en las entradas. Obtenga más información sobre los datos con desequilibrios.
Imputación de valores de características que faltan	Listo	Se han detectado e imputado valores de características que faltan en los datos de entrenamiento. Si se esperaba que faltasen valores, deje que se complete la ejecución. De lo contrario, cancele la ejecución actual y use un script para personalizar el control de los valores de características que faltan, de modo que sean más adecuados al tipo de datos y a las necesidades de negocio. Obtenga más información sobre la imputación de valores que faltan.
Detección de la característica de cardinalidad alta	Correcto	Se han analizado las entradas sin que se hayan detectado características de cardinalidad alta. Obtenga más información sobre la detección de características de cardinalidad alta.

Figura 55: Insights mostrados por AutoML.

2. Modelos evaluados: se muestra un listado de los modelos y parámetros utilizados para la comparación, mostrando en el tope, el mejor modelo resultante.

Nombre del algoritmo	IA responsable	Valor pondera...	Muestreo	Fecha de creación	Duración	Hiperparámetro
VotingEnsemble		0.89559	100.00 %	Mar 15, 2026 4:59 AM	5 m 16 s	algorithm: [XGBoostClassifier] ...
StandardScalerWrapper, XGBoostClassifier		0.88922	100.00 %	Mar 15, 2026 1:31 AM	2 m 10 s	booster: gbtree colsample_by: ...
StandardScalerWrapper, XGBoostClassifier		0.88793	100.00 %	Mar 14, 2026 11:48 PM	2 m 30 s	booster: gbtree colsample_by: ...
StandardScalerWrapper, LightGBM		0.88791	100.00 %	Mar 15, 2026 4:06 AM	1 m 29 s	boosting_type: gbdot colsample: ...
StandardScalerWrapper, XGBoostClassifier		0.88662	100.00 %	Mar 15, 2026 2:01 AM	3 m 6 s	booster: gbtree colsample_by: ...
StandardScalerWrapper, XGBoostClassifier		0.88641	100.00 %	Mar 14, 2026 11:45 PM	1 m 26 s	booster: gbtree colsample_by: ...
StandardScalerWrapper, XGBoostClassifier		0.88598	100.00 %	Mar 15, 2026 4:00 AM	1 m 51 s	booster: gbtree colsample_by: ...
StandardScalerWrapper, XGBoostClassifier		0.88584	100.00 %	Mar 15, 2026 4:09 AM	1 m 1 s	booster: gbtree colsample_by: ...

Figura 56: Nuevo trabajo de ML automatizado - Completado.

3. Código y pipelines generados.

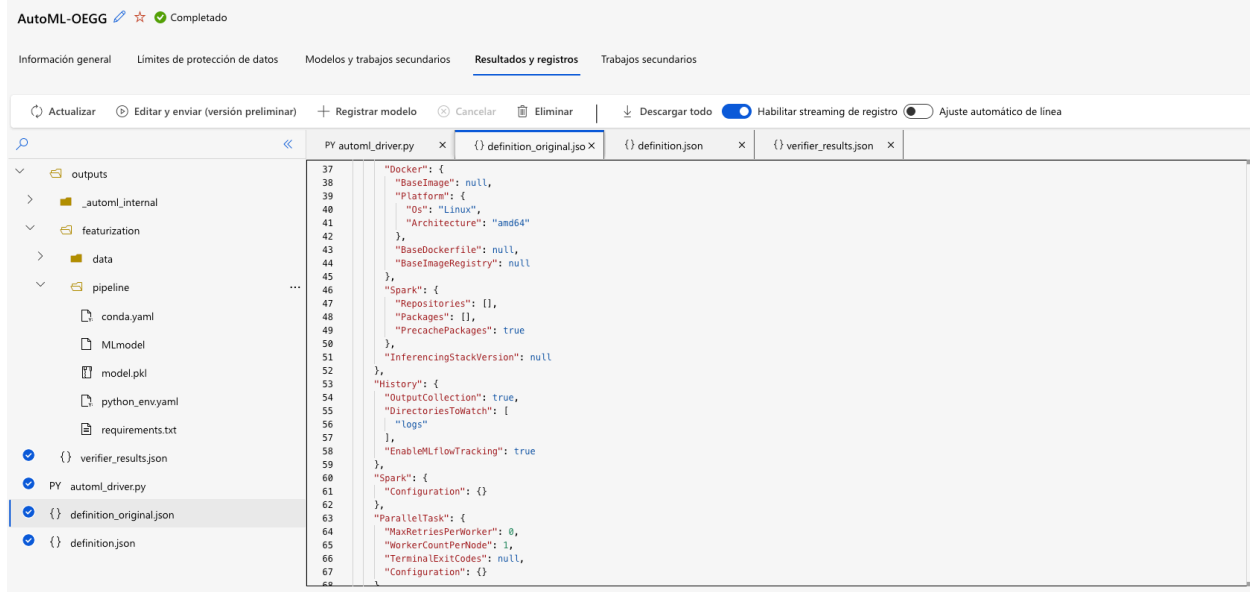


Figura 57: Código generado para la replicación del modelo.

De igual forma, podemos ver una pantalla de resumen sobre el nombre del algoritmo resultante, el valor de la métrica de AUC (y otras métricas), así como un link para ver los detalles del conjunto.

Entradas

Nombre de entrada: training_data
Recurso de datos: [Australian_Rain_AutoML:1](#)
URI del recurso:

Salidas

Nombre de salida: best_model
Modelo: [azureml_automl-oegg_183_output_mlflow_log_model_2140996201:1](#)
URI del recurso:

Resumen del mejor modelo

Nombre del algoritmo
[VotingEnsemble](#)

Detalles del conjunto
[Ver detalles del conjunto](#)

Valor ponderado de AUC
0.89559 [Ver todas las demás métricas](#)

Muestreo
100.00 % ⓘ

Figura 58: Pantalla de resumen del trabajo de ML automatizado

Detalles del conjunto



Seleccione un algoritmo de conjuntos para ver los pesos y los hiperparámetros del conjunto.

- ☒ StandardScalerWrapper, XGBoo...
- ☐ StandardScalerWrapper, LightG...
- ☐ SparseNormalizer, XGBoostClas...
- ☐ StandardScalerWrapper, Linear...
- ☐ StandardScalerWrapper, XGBoo...
- ☐ StandardScalerWrapper, XGBoo...
- ☐ StandardScalerWrapper, XGBoo...
- ☐ StandardScalerWrapper, XGBoo...
- ☐ StandardScalerWrapper, XGBoo...
- ☐ StandardScalerWrapper, Rando...

Peso del conjunto: 0.2

Transformación de datos:

```
1 {
2   "class_name":
3   "StandardScaler",
4   "module": "sklearn.
5   preprocessing",
6   "param_args": [],
7   "param_kwargs": {
8     "with_mean": false,
9     "with_std": false
10  },
11  "prepared_kwargs": {},
12  "spec_class": "preproc"
13 }
```

Algoritmo de entrenamiento:

```
1 {
2   "class_name":
3   "XGBoostClassifier",
4   "module": "automl.client.
5   core.common.model_wrappers",
6   "param_args": [],
7   "param_kwargs": {
8     "booster": "gbtree",
9     "colsample_bytree": 0.
10  5,
11  "eta": 0.5,
12  "gamma": 0,
13  "max_depth": 5,
14  "max_leaves": 3,
15  "n_estimators": 400,
16  "objective":
17  "reg:logistic"
18 }
```

Figura 59: Detalles del conjunto. Transformaciones y modelos utilizados.


Y, al dar clic sobre el link del algoritmo, se nos abrirá una nueva pantalla, donde podremos ver otra serie de cosas:

1. Resumen del modelo, métricas y modelos registrados.

The screenshot displays the Azure ML AutoML-OEGG interface for a specific model. The breadcrumb navigation at the top reads: `... > azureml-mna > ML automatizado > Default > AutoML-OEGG > happy_stamp_6t4xd24b`. Below this, the model name `happy_stamp_6t4xd24b` is shown with edit, favorite, and completion status icons. A horizontal tab bar includes 'Información general', 'Modelo' (selected), 'Métricas', 'IA responsable (versión preliminar)', 'Transformación de datos (vista previa)', and 'Resultados de la prueba (versión preliminar)'. A secondary bar contains action buttons: 'Actualizar', 'Implementar', 'Descargar', 'Explicar modelo', 'Ver código generado', 'Modelo de prueba (versión preliminar)', and 'Registrar modelo'. The main content area, titled 'Resumen de modelo', lists the following details:

- Nombre del algoritmo:** VotingEnsemble
- Detalles del conjunto:** [Ver detalles del conjunto](#)
- Valor ponderado de AUC:** 0.89559 [Ver todas las demás métricas](#)
- Muestreo:** 100.00 % ⓘ
- Modelos registrados:** Registro todavía no disponible
- Estado de la implementación:** Sin implementaciones aún

Figura 60: Pantalla de resumen del trabajo de ML automatizado



The image shows a screenshot of a software interface titled "Ejecutar métricas" (Execute metrics) with a close button (X) in the top right corner. The interface displays a list of 12 metrics and their corresponding values. The metrics are grouped into three sections: Precision/AUC, Precision/Recall, and F1 score. The values are displayed in a light blue font.

Métrica	Valor
Precisión	0.85138
Macro de AUC	0.91763
Micro de AUC	0.96314
Valor ponderado de AUC	0.89559
Macro de puntuación de precisión media	0.82269
Micro de puntuación de precisión media	0.92876
Valor ponderado de puntuación de precisión media	0.90772
Precisión equilibrada	0.69942
Macro de puntuación de F1	0.74307
Micro de puntuación de F1	0.85138
Valor ponderado de puntuación de F1	0.84233
Pérdida de registro	0.35581

Figura 61: Listado de métricas resultantes del trabajo de ML automatizado.

2. Métricas: en esta pestaña podremos ver una serie de gráficos y valores que fueron evaluados en las diferentes iteraciones del trabajo.




Figura 62: Pantalla de gráficos y métricas del trabajo de ML automatizado

3. Transformaciones realizadas: en esta pestaña podremos ver las diferentes transformaciones que se le realizaron a nuestro conjunto de datos.

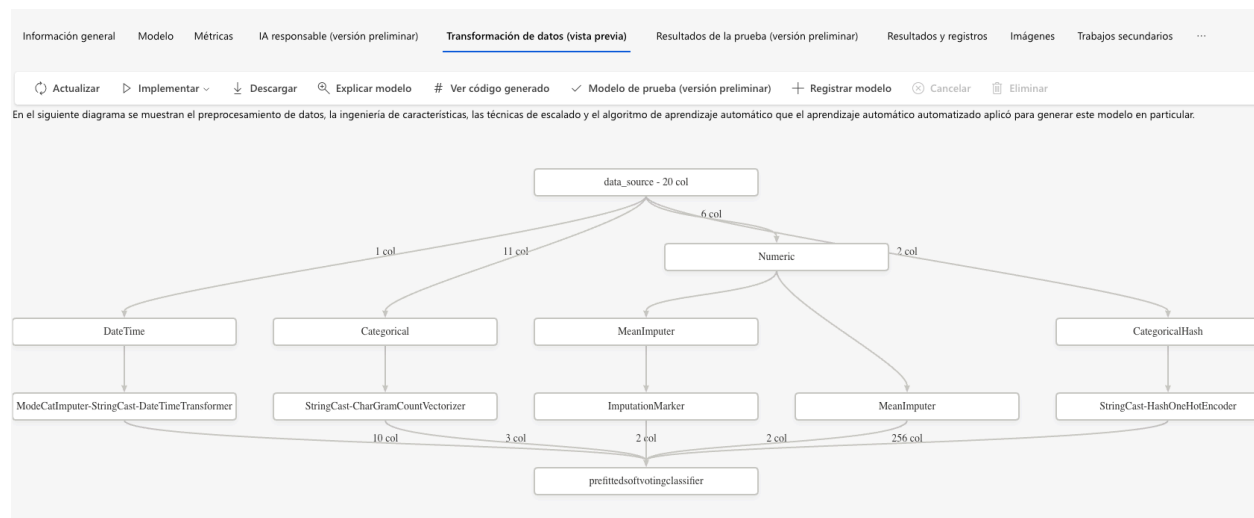


Figura 63: Pantalla de transformaciones aplicadas a nuestros datos.

De esta forma, podemos ver, AutoML es una herramienta súper potente, que automatiza muchas de las tareas repetitivas o «tardadas» que deben realizar los científicos de datos, como lo son: exploración de datos, selección de modelos, limpieza previa, ajuste de hiperparámetros, validación cruzada, etc. y que, de esta forma, los científicos pueden eficientar en gran medida su trabajo, al tener todo concentrado en un solo lugar y de forma automática y concentrarse más en el análisis de los datos, métricas y resultados.

3.4. Implementación del modelo para predicciones

Adicionalmente, AutoML nos permite implementar nuestro modelo resultante, por ejemplo, mediante un servicio web. Para ello, debemos regresar a nuestra pantalla general del modelo y seleccionaremos la opción Implementar -> Servicio Web.




Figura 64: Implementación de nuestro modelo en un servicio web.

Posteriormente, configuraremos nuestra implementación:

Implementación de un modelo ✕

Nombre * ⓘ 👁

my-automl-deploy

Descripción ⓘ

Tipo de proceso * ⓘ

Instancia de contenedor de Azure ⌵ *

Modelos: automloegg183

Habilitar autenticación

☒

Este modelo es compatible con [implementación sin programación](#). Puede invalidar **opcionalmente** el entorno y el archivo de controlador predeterminados.

Usar recursos de implementación personalizados

☐ Usar recursos de implementación personalizados

> Avanzadas

Implementar **Cancelar**

Figura 65: Configuración de la implementación de nuestro modelo.

Y, al dar clic en el botón «Implementar», volveremos a nuestra pantalla inicial, donde se mostrará un aviso en color verde, donde menciona que la implementación se ha

desencadenado correctamente. Después de ello, debemos esperar a que el estado de la implementación cambie de «En ejecución» a «Completado».




Figura 66: Pantalla de estado de la implementación.

Una vez que haya sucedido esto, podremos hacer el consumo de nuestro modelo, a través del endpoint generado, siguiendo el repositorio: <https://github.com/Azure-Samples/rag-data-openai-python-promptflow/tree/main>

4. Reflexión

El Aprendizaje Automático Automatizado (AutoML) surge como una solución para agilizar y optimizar el desarrollo de modelos. Actúa como un «asistente experto» que entrena cientos de combinaciones de algoritmos y configuraciones para encontrar la mejor opción para un conjunto de datos específico.

Ventajas de AutoML:

- **Eficiencia:** Automatiza tareas tediosas como la selección de algoritmos (desde modelos lineales hasta redes neuronales o boosting como XGBoost), el ajuste de hiperparámetros y la validación cruzada.
- **Ingeniería de Características Automatizada:** Maneja automáticamente valores nulos, codificación de variables categóricas y escalado de datos numéricos.
- **Insights de los datos:** Genera análisis automáticos sobre los datos, como detecciones de desbalanceo de clases y cardinalidades.
- **Optimización del Talento:** Permite que los científicos de datos se concentren en el análisis de resultados y métricas estratégicas en lugar de en tareas operativas.

Desventajas y Consideraciones de AutoML:

- **Consumo de Recursos:** Dependiendo de la configuración y la complejidad de los datos, el proceso de entrenamiento automático puede durar horas.
- **Costo:** Al probar múltiples modelos en la nube, es fundamental monitorear el uso de máquinas virtuales para evitar costos imprevistos.
- **Necesidad de Supervisión:** Aunque automatiza gran parte del proceso, la calidad del modelo final sigue dependiendo de la calidad de los datos de entrada y de una correcta selección de métricas de desempeño por parte del usuario.

En conclusión, el uso de herramientas de AutoML en la nube representa un salto significativo en la productividad, permitiendo pasar de la carga y análisis de datos crudos a modelos implementados en producción con una intervención manual mínima.

5. Referencias

- [1] Rimini Street, «What is Microsoft Azure's AutoML and How Does it Accelerate Machine Learning?». Accedido: 17 de marzo de 2026. [En línea]. Disponible en: <https://www.riministreet.com/blog/what-is-microsoft-azures-automl-and-how-does-it-accelerate-machine-learning/>
- [2] Microsoft, «Deploy online endpoints and components for real-time inference». Accedido: 17 de marzo de 2026. [En línea]. Disponible en: <https://learn.microsoft.com/en-us/azure/machine-learning/how-to-deploy-online-endpoints>
- [3] Microsoft, «Tutorial: Entrenar un modelo de clasificación con AutoML sin código». Accedido: 17 de marzo de 2026. [En línea]. Disponible en: <https://learn.microsoft.com/es-mx/azure/machine-learning/tutorial-first-experiment-automated-ml>
- [4] Microsoft, «Descripción de los resultados del aprendizaje automático automatizado». Accedido: 17 de marzo de 2026. [En línea]. Disponible en: <https://learn.microsoft.com/es-mx/azure/machine-learning/how-to-understand-automated-ml>
- [5] Microsoft, «What is automated machine learning (AutoML)?». Accedido: 17 de marzo de 2026. [En línea]. Disponible en: <https://learn.microsoft.com/en-us/azure/machine-learning/concept-automated-ml>